

Object

دالةฟังก์ชัน $y = f(x)$ หนึ่งตัวแปร

لما نتكلم عن الـ Learning (أي أن يفهم الـ Linear-Function) (Linear approximation)

Second derivative

First driving

maximum ✓

(- negative definite)

(Image) (Ludwin) Vinge

function

Vector value

تاریخ ۱۳۰۲

21. 10. 1941

Vector Spaces

single
variable

maximize

$R^n \rightarrow R^{\text{dimension 1}}$

مجلس


و کما مقرر شد

- Contour plot of a multivariable function, $f(x, y)$

Contour Plot : \Rightarrow Surface and Function Plotting

الـ Gradient مظهر في فراغ one dimension ولو فراغ n dimension متى كانت في فراغ n dimension $f(x, y, z) \rightarrow$ scalar function

لنأخذ الـ Simplex الهولندي Simulation وعلينا أن نفهم الـ 2d flow training



11 Contour Plot ليظهر على انلا ينقطع عند ارتفاعات متساوية

differentiable (x, y) يدعى نفس الـ Z (على نفس البر شعاع)

نظر القضاة والكنز بتولياتهم ومخالفاتهم

في المقادير المذكورة (تفسير) يتغير كل نفس الإرتفاعات، وفيه الدالة

لدينا المسامحة لتبقى ضيقة كت في جنب وواسعة في حمة ثانية

أولاً: نلاحظ عند مسامحة ثابتة كقيم α (خالص) لما يكون الجهد يتناقص

كثير يكون الأسرع - لما يخرج من فوهة حذوفة بالسيكارة

جلسه ۱۱ (۲۷) از ۱۰۱۱ با عنوان بیرون آمدن از ۱۰۱۱

ومن - - - - - ما يطرأ على الدنيا من ما يتغير قليلا

the domain of the function $f(x)$ is the set of all x for which $f(x)$ is defined.

ازای و یوحنا لفتن علی بن یوحنا از حاکم قیوم الدین و فرقه حسن و یونس (۱۰۸۰)

في الدراسة يأتي (Contact) يتكون من $2n$ زوايا $2n$ كروية فنقدر مجموعها من

خلال القبة أو الألواح

لها أنواع على حسب الارتفاع، وهي

(-)e

Scalar \rightarrow ϕ \rightarrow Vector

ولما ينزسوها ينزسها ٥١٨

ومينر سميث ال (18-) (مستشار في الهندسة المدنية، 1900-1970)

ایکٹر ایٹم وون غفر کی 4 فرماں جو ۲-۲ فینٹس Valter

صلى الله عليه وسلم

[illegible]

الرئيسية كذا (1878) في النظام ١٠. مستقلة لوتنت (1878) ومشتقة (1878)

منحنى (Curve) هو دالة (Function) لأن يمكنه ديفرنتيبل (Differentiable) ديفرنتيبل (Curve)

- Parameterization (نمذجة)

مکرمہ کیونکہ ۱۱ ۱۲/۱۲ مہینہ عن اکرمہ بن مقبیر یروا

Skalar
funktion

∇

$\nabla f = \begin{pmatrix} 2x \\ 2y \end{pmatrix}$

بیمبر و انبیاء
یداد
Vector field

ما إذا تقبل ترسيم على ثنائي في P/I أو P/I $\rightarrow P/I$
 $\mathbb{R}[x] \rightarrow \mathbb{R}[x]/I$
 $(x^2) \rightarrow (x^2) + I$

Vector field \vec{F} is a vector field

(- Tip کی Vector اور Length (باقی Vector مختلفہ کی) - اور مساوی

الـ V_{eff} عند النقطة $\theta = 0$ $V_{eff} = V_{eff}(0)$ $V_{eff}(0) = V_{eff}(0)$ $V_{eff}(0) = V_{eff}(0)$

في متعلق في بعض قسوسها رضاء علم اللوز مثلاً .

~~Current C-direction~~

Vector

7. 11. 1954

$$f(x, y) = \begin{bmatrix} ax + by \\ cx + dy \end{bmatrix}$$

$(\text{int} \cdot A) \leftarrow \text{linear}$ very structure بها أو الخطية

Transformation من وجهة نظر A و B و C

$$f(x,y) = \begin{bmatrix} 6x+2y \\ 6x-2y \end{bmatrix} = \begin{bmatrix} 7 \\ 9 \end{bmatrix}$$

میکر از سوس Vector field

- Transformation انتاج

Functions as Transformations:

~~ال~~

L.T. : 0/8 . ص ۱۱

على نقطة الأوتار والتوتر بين خطوط الشبكة والقطعة المدمجة (تحول إلى قطرة مستوية)

(٦٥ من ال) (٦٦ من ال) وملاحظات ٢٠٢٠-٢٠٢١ ومن الخط المستقيم يتحول للنقطة

صحتی بعمل می آید از این که در بعضی موارد (مثلاً) غیر منتظمی در (علاقه)

مركز نقطة الأمل تتحرل من مكانها .


Liberty:-

Function not continuous if Function Approaches ∞ or $-\infty$

~~Derivative~~ $\lim_{x \rightarrow 0} f(x)$

$\lim_{\Delta x \rightarrow 0}$

Gradient :-



مدرستك قديمة ال Parameters رة قديمة

قيمة الممتلكات المكتسبة والتشويق إلى الأمانة

بیتہ و بینہ ال احکامہ و احکام ال E_{77777} بقیر حاکم ال E_{77777} عدل بقیر ال E_{77777} بیتہ و بینہ E_{77777}


ولیکن w due to change in $J(w)$, error $J(w)$, w

لوا المعدل التغير كبير يبقى محتاج التغير الى ما يقين كبير. على تقدير اوسط التغيرية

[illegible]

ω small T is large $\Rightarrow \frac{dT}{d\omega} \approx -\frac{1}{\omega} \Rightarrow \frac{\Delta T}{T} \approx -\frac{\Delta \omega}{\omega}$ $T(\omega)$ is low \Rightarrow

Positive Evidence



لوحات و اشیاء ۵۵ نفر سابقه ۱۰۰۰ کلید و ۱۰۰۰ کلید و ۱۰۰۰ کلید

کرماتنا محتاج اغیر مراد به کلمات جدیدین علمین کریم

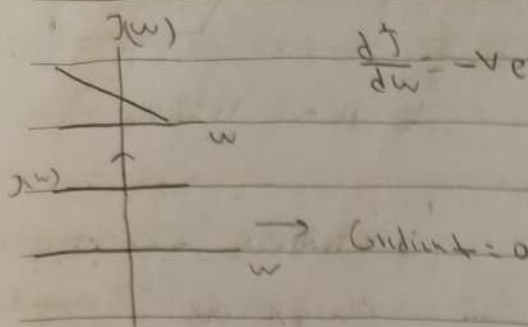
حقوقی w_1, w_2 و سطح $\frac{dT}{dw_1} = 100$ ، $\frac{dT}{dw_2} = 5$ من حیثاً در مورد Training Loss

ص ٢٤٧ و عروا ٢٦٧٥ زكبر - بغير اكبر وا لينة لو ان غير واحد ال ٢٦٧٥

صيفير ١٤٥٠ رة المحتارة التتم بقة الحكيد لانة يولدر علوا (١٧٧٧)

عندی تا اعراف فاشید کل Parameter را در error
نقل

• لا قل error

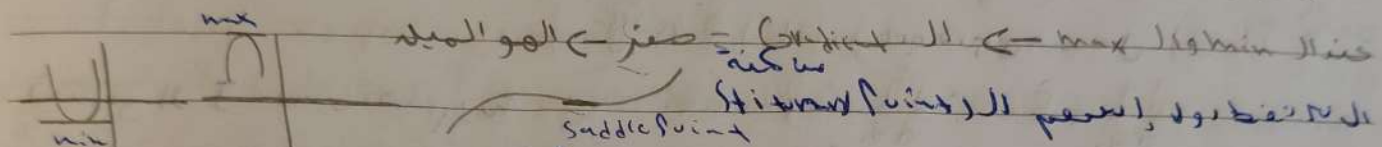


مشتق الـ $f(w)$ سالب
فما لنا الـ $f(w)$ ينزول w نزل

مما نريد الـ $f(w)$ لا ينزل

حصلنا شئ كبير في الـ $f(w)$ مع ان الـ w لا يتغير شئ فحصل

كارثي في الـ $f(w)$ - الـ Gradient Vector يربط علاقة بين تغير w والتغير في $f(w)$ خاصية شئ.



عند الـ $f(w)$ max - الـ Gradient = صفر - هو الميل

الـ $f(w)$ نقطه سرجية - الـ Gradient = صفر - هو الميل

الـ Gradient صفر $f(w)$ لما يكون عدد $f(w)$ كبير

لأنه على الـ $f(w)$ تكون خالية للتفاضل تكون معرفة عن النقطة - لو ضلنا التفاضل عند

نقطة غير معرفة يبقى ملوالت تفاضل أصلاً ودة بتعمل مشكرف الـ $f(w)$ فلو الـ $f(w)$ كانت

مستمرة $f(w)$ عند نقطة معينة يبقى شئ سيكون لها derivative فبتشعر شئها $f(w)$ بامتداد

الـ Gradient Descent ودة سوال بكم

النيق

شروط فنتكون الـ $f(w)$ للتفاضل (1) متصلة (النهاية اليسرى = النهاية اليمينية = في الحالة عند النقطة)

(2) $f(w)$ (المتغير اليسرى = المتغير اليمين) (3) موضع الخط الصفر

فما بتعمل $f(w)$ فلو الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

لما بتعمل $f(w)$ فلو الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

بعضها $f(w)$ فلو الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

بعضها $f(w)$ فلو الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

بعضها $f(w)$ فلو الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

اليوم الثاني كذا تكون الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

يكون نعلن كذا كذا الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

Finding min/max of a function: $f'(x) = 0$ at min, max

المتغير الثاني هو التغير في $f(w)$ فلو الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

الـ $f(w)$ لا خط ولا $f(w)$ بين الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

الـ $f(w)$ لا خط ولا $f(w)$ بين الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

لو الـ $f(w)$ زار دة عن x شئ فتعرف شئها بكم الـ $f(w)$ متدا و فجاه الـ $f(w)$ زار دة واحدة ممكن يكون

(American) Newton-Raphson (solution)

Chain Rule:

$$x = f(u)$$

$$v = f(x)$$

$$v = \frac{dx}{dt}$$

$$a = f(v)$$

$$a = \frac{dv}{dt}$$

f is linear

$$\frac{da}{dt} = \frac{da}{dv} \cdot \frac{dv}{dx} \cdot \frac{dx}{dt}$$

$$f(x) = e^{(3x^2+1)} \rightarrow f(x) = e^u$$

$$\frac{df}{du} = e^u$$

يمكن نيجر هذا بالترتيب

$$u = 3x^2 + 1$$

$$\frac{du}{dx} = 6x$$

$$\frac{df}{du} \cdot \frac{du}{dx} = e^u \cdot 6x = 6xe^{3x^2+1}$$

رأي من أهمية Chain Rule !! 1. Training ML و DL بشكل كبير


Linear regression $h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$

cost $J(\theta) = \frac{1}{2} \sum_{i=1}^n (y_i - h_\theta(x_i))^2$

$$\frac{dJ}{d\theta_0} = 5, \quad \frac{dJ}{d\theta_1} = 3$$

تغير في J عند تغير المعاملات

Linear model علاقة مباشرة بين z و y



$$z = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

المخرجات DL

$$m \text{ samples } = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$J = f(z)$ Backpropagation لحساب العلاقة بين z و J

Backpropagation عبر كل layer ويكون

في Function حيو بعض كثير

$$y = f(x) \quad v = \frac{dy}{dx} \quad a = \frac{d}{dx} \left(\frac{dy}{dx} \right) = f''(x) = \frac{d^2 y}{dx^2}$$

المشتقة الثانية تقول النقاط السيل هي max و min

$f''(x) > 0$ -> نقطة minimum
 $f''(x) < 0$ -> نقطة maximum
 محدبة لا عميقة -> الدالة الأسطوئية
 محدبة لا عميقة -> الدالة الأسطوئية

Convex Function (Global minimum) واحد

Concave function (Global maximum) واحدة

/ /

تغير ال Function بتغير كل من x و y . $f(x, y) = x^2 y^2$. $\frac{\partial f}{\partial x} = 2xy$ عند ثبات y لا و $\frac{\partial f}{\partial y} = 2xy$ عند ثبات x . $\frac{\partial f}{\partial x}$ Component for x

عند تثبيت x وروية تتغير الدالة بالنسبة لـ y $\rightarrow \frac{\partial f}{\partial y} = 2y$ ← Component في اتجاه y

طوبولوجيا و تغيير الدالة لو غيرت الإشتين مع بعضه :-

Gradient vector = $\begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} x \\ y \end{bmatrix}$

2 component vector

تغيير واحد ك واحد component

تغيير واحد ك واحد component

steepest ascent $\nabla f(x, y)$

هذا فالـ Gradient Vector يقول لنا الـ Function يتغير (ازاي) لو ازل لا والله وانتي ويا مع بعض
لأعابتجيبوا فهو يمشاورك راحة أقط ميل يعني لو مشيت كذا
مبدأ أولي ← وهكذا فنأيت لو عاوز توصل بأوسع وطيلة فالاستاذ المثلث هو راحة

فكر بسيط . لو عاوز اوجد minimum بيقس عكس اتجاه ∇ Gradient
 لو طول انظر طريقة (رايثا) Gradient عمودي على (Contour plot)
 طبليه الـ Gradient بيبدأ من الـ (steepest ascent)
 بقدرت بـ حاح اسمها directional derivative !!!

Directional derivative :-

لوعاوز احييد (uncomfortable) راحة (Gradation) في V_1, V_2 باعتبارهم

$$\Delta f \cdot v_1 = 11 \Delta f \parallel \frac{1}{v_1} \parallel \cos \theta$$

mit
Vektor

رابطه اضربين \rightarrow (وفا) Δf الواحد

الواحد (Maximum) لو كارا (ع-ص) يعني لو كار مفيد زاوية

فريق الحركة في اى اشياء عيдал μ واحدة حذرا μ وليست كمال μ

قوتله مراد، اكراد قريه راشه، قريه غدير، و طغوز برقع، و استانبول

الـ Al^{3+} في أي راحة ما عد' الـ Al^{3+} هو جزيء الـ Al^{3+} الـ Al^{3+} الـ Al^{3+}

Gradient = Directional Derivative في اتجاه واحد (Gr-ient)

ليكون أكثر من 100. (أيضا لا يستطيع باطرس لقوة)

Positive Definite Matrix \rightarrow eigenvalues positive
 Negative Definite Matrix \rightarrow eigenvalues negative

Object

Indefinite Matrix \rightarrow

Negative

Positive and negative

Date

/

/

Part 3

$$f(x, y) = x^2 + y^2$$

$$\nabla f(x, y) = \begin{bmatrix} 2x \\ 2y \end{bmatrix}$$

Vector

\mathbb{R}^2

Vector value \mathbb{R}^2

Vector field \rightarrow Vector field expression and Gradient

Gradient \rightarrow Vector field \rightarrow Gradient \rightarrow Vector field

Stationary Point in 3D

$$f(x, y) = x^2 y^3 \quad \nabla f(x, y) = \begin{bmatrix} 2xy^3 \\ 3x^2y^2 \end{bmatrix}$$

$$\nabla f(x, y) = 0$$

Stationary

Matrix

Stationary Point in 3D

min

max

Saddle Point

min \rightarrow maximum \rightarrow saddle point

Stationary Point \rightarrow Saddle Point

Stationary Point \rightarrow Saddle Point

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial x \partial y} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} = \begin{bmatrix} 2y^3 & 6xy^2 \\ 6xy^2 & 6x^2y \end{bmatrix}$$

$$= \begin{bmatrix} 2y^3 & 6xy^2 \\ 6xy^2 & 6x^2y \end{bmatrix}$$

Symmetric matrix

Hessian matrix

Stationary Point \rightarrow Saddle Point

$$H(x, y)$$

Negative Definite Matrix

Indefinite Matrix

$f(x, y) \rightarrow \min$

$f(x, y) \rightarrow \max$

$f(x, y) \rightarrow \text{indeterminate point}$

$$y = f(u) \quad u = f(x) \rightarrow y = f(f(x))$$

Part

Chain Rule in multi variable :- $z = f(x, y) = x^2 y$

$$\frac{dz}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt} + \frac{\partial f}{\partial z} \frac{dz}{dt}$$

$$x = f(t), \quad y = f(t)$$

$$\frac{dz}{dt} = \frac{\partial f}{\partial x} \cdot \frac{dx}{dt} + \frac{\partial f}{\partial y} \cdot \frac{dy}{dt}$$

$$1) f(x, y, z)$$

$$\begin{aligned} x &= f(t) \\ y &= f(t) \\ z &= f(t) \end{aligned}$$

$$\nabla f(x, y, z) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{bmatrix}$$

$$\vec{V} = \begin{bmatrix} x(t) \\ y(t) \\ z(t) \end{bmatrix}$$

$$\frac{df}{dt} = \nabla f \cdot \vec{V}(t)$$

$$= \nabla f \cdot \frac{d\vec{V}}{dt}$$

$$\vec{V} = \begin{bmatrix} \frac{dx}{dt} \\ \frac{dy}{dt} \\ \frac{dz}{dt} \end{bmatrix}$$

$$z = f(x_1, x_2) = x_1^2 - x_2^2$$

$$\nabla = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}$$

$$x_1(u_1, u_2) = 2u_1 + 3u_2$$

$$x_2(u_1, u_2) = 2u_1 - 3u_2$$

$$u_1(t) = \cos\left(\frac{t}{2}\right)$$

$$u_2(t) = \sin\left(\frac{t}{2}\right)$$

$$\frac{du}{dt} = \begin{bmatrix} \cos\left(\frac{t}{2}\right) \\ \sin\left(\frac{t}{2}\right) \end{bmatrix}$$

$$\frac{\partial x}{\partial u} = \begin{bmatrix} 2 & 3 \\ 2 & -3 \end{bmatrix}$$

$$\frac{df}{dt} = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}^T \cdot \begin{bmatrix} 2 & 3 \\ 2 & -3 \end{bmatrix} \cdot \begin{bmatrix} \cos\left(\frac{t}{2}\right) \\ \sin\left(\frac{t}{2}\right) \end{bmatrix}$$

Jacobian

$$\nabla f^T = \begin{bmatrix} 2x_1 & -2x_2 \end{bmatrix}$$

Jacobian matrix

$$y = f(x) = x^2 + 2x - 1$$

$x > 0$ → من غير صفر

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

Quadratic solution

approximation ← iteration ← numerical solution

$$f(x) = x^3 + x - 1$$

$$f(1) = 1$$

الحل المطلوب

3) evaluate

F.V error

يوجد الخطأ بقدر

$$f = 12$$

$$f = 0$$

4) Check error or margin

5) Update for x → في حاجة
الحل (0)

الخطوة التالية من x فهاون

تقلص عدد الـ iterations التي

1) Newton-Raphson method


(Update equation) definition

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)} \rightarrow y(x_1) = 0$$

$$x_2 = x_1 - \frac{f(x_1)}{f'(x_1)}$$

$$f'(x_0) = \frac{dy}{dx}$$

$$x_0 - x_1$$



الخطوة التالية عند النقطة

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

الخطوة التالية عند النقطة

مقبولة. 2) لو كانت في نقطة جيب (الخيار الثاني) صغير

صغير جيب "فالـ update صغير كبير جيب" فويل

من الحل بآخر ولو كان صغير

Day 3 Part 1: Taylor Series Approximation

Foundation

Newton-Raphson

Gradient Descent

Second order Optimization

لو عارف الـ function عند نقطة معينة نقطو واحدة

Function value عند النقطة

كل ما نحتاجه من النقطة

عن النقطة والـ F.D عند النقطة والـ D.D عند النقطة

1) Constant Approximation

2) Line Approximation

$$f(x) \approx f(a) + f'(a)(x-a)$$

Newton method

[illegible]

Hessian-matrix

6428500 6500-2

Object


First order of the day

Date _____

1. 1

ج، ۶ optimizaty

مربعین کا حساب الگ الگ First order میں دیتے ہیں



Minimum of 2000 words. 10% discount on 2000 words. 10% discount on 2000 words.

طیلولو عاوز او حل لا حینا عرضوا فی خطوة واحدة ری

- Skundvder 11 je sines
optimization

Function to the nearest 11 Approximation Error

Ministry of Education

الـ Pyrex في الـ Data نفسها بيحسد من الـ Windows مملوطة علاقة بين حاسب الفاتة

(overfitting) Validation Error كبير (overfitting) Error
 (underfitting) Error صغير (underfitting) Error

الـ (Lagrange) طريقة لإيجاد تقريبات (approximation) للدالة (cost function) عند نقطة التحسين (optimization)


له المده ولكن اختيار المدة

model ولكن اختيار (model) (n)
 طريقة (منهج) على (function) (n) لحدود
 F.O.A } minimization
 S.O.A } iterative

Day 3: P-42:- EXPONENTIALLY WEIGHTED MOVING AVERAGE (EWMA)

Relative and Quantitative Averaging of something

(المنقطة الغنية بتحتوي على ثقل كثير)












تظهر في الصورة وحش ورجل الحداثة لتيفر باستندة في (١٢٧٦) سنة بعد ميلاد

صليبي ١٧٧٧ عنى خالصه والقبايل طاح حار او شمس موجو، فيميكور

model ^{data} ML // 3 overfitting // noise

- heute II



١. محاولة ال (curve) النظري (١)         

صلى الله عليه وسلم عليه الصلاة والسلام .

جو ریفریکٹو انڈیکس 1.5 ہے

نصفه نو استقر روی مشاوارز بسبب حرارت ۹۷۸۶۰

۲-۱۱ و تحب و ریسر تانی نقطه حدی



Shredding
fur line

سج window
ستارہ
نقشہ

$$\begin{array}{cc} T_2 & V_2 \\ T_1 & V_1 \end{array}$$
$$V_T = \beta V_{T-1} + (1 - \beta) T_t$$

\downarrow \downarrow
 0,9 0,7

Funktion \rightarrow hyperbolic decay

$\beta < 1$

كل ما زاد عن النقطة القدسية كل ما وزنها يقل ويقل وكل ما حاز من العائدين

الـ curve اللينيج يكون expansion رائع الـ β اللينينج

Experiments

→ وزن علی واحد بیدار

١٧٩ - ٢٥٥

من نقاط حفظ عرفان.

[illegible]

مذلول ۵۰ و اکثر قریب مضبوطی اده

خوارزمية التلافيف (Convolution) → نفس الوقت

مع زيادة الارتفاعات وأولها عند ٥٠ متراً بين الجذرة تحت غلظتين متعلقتين محتاطين

V_t
 $1 - B^*$ ← correlation

Accuracy \uparrow \leftarrow Moving average \leftarrow washing

Conductance \uparrow \leftarrow expansion

Bias Corrections
Full

سید جمیل علی احمد ڈاکٹر ADWent 28/1/2022

لو عدت طرف علی حسب قضیه ۱) بپوشیده یعنی $\frac{1}{1-\beta}$ و برعکس $\frac{1}{1-\beta}$ برکام