

البيانات التي نستخدمها في الـ optimization  
 Model:  $y = f(x)$   
 Data:  $x_1, x_2, \dots, x_n$   
 Target:  $y_1, y_2, \dots, y_n$   
 Loss:  $L(y, \hat{y})$

ML problem:  $f(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$   
 Parameters:  $\theta_0, \theta_1, \dots, \theta_n$   
 Features:  $x_1, x_2, \dots, x_n$   
 Target Label:  $y$   
 Independent Variable:  $x$   
 Dependent Variable:  $y$

Linear Regression:  $y = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$   
 Logistic Regression:  $\hat{y} = \frac{1}{1 + e^{-z}}$   
 Sigmoid Function:  $\hat{y} = \frac{1}{1 + e^{-z}}$   
 Non-linear:  $z = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$

Neural Network:  $z = b + w_1 x_1 + \dots + w_n x_n$   
 Deep N.N:  $\hat{y} = g(z) = \frac{1}{1 + e^{-z}}$   
 Activation Function:  $g(z)$

Learning:  $\hat{y} = f(x_1, x_2, \dots, x_n)$   
 Features:  $x_1, x_2, \dots, x_n$   
 Parameters:  $\theta_0, \theta_1, \dots, \theta_n$   
 Hypothesis:  $\hat{y}$   
 Actual Target:  $y$

How to find the Parameters:  $\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$   
 Example:  $\hat{y} = 100$  when  $x_1 = 1, x_2 = 1$   
 $100 = \theta_0 + \theta_1 + \theta_2$   
 $150 = \theta_0 + 2\theta_1 + \theta_2$   
 Analytical Solution:  $\begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} 100 \\ 150 \end{pmatrix}$   
 Approximate Solution:  $\begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix} \approx \begin{pmatrix} 100 \\ 150 \end{pmatrix}$

- $\Delta$  is error, Approximation

11. Find the Approximate  $\Delta G^\circ$  Solution of the

ليخدين ال ١٧-١٨ / فخر ما يمكنه

Algebraische Lösungen

[illegible]

$$X\theta = y \quad \hat{\theta} = (X^T X)^{-1} X^T y$$

last method  $\theta = x^T (x x^T)^{-1} y$

في حالة التذبذب في سرعة الدوران  $\rightarrow$  Normal Equation

Mathematische Beweismethoden (2. Vorlesung) - Exkurs in die Logik

Hind      Kink      Numerical      Approximate      Solution

التحليل (Regression Analysis) أقل ما يمكن وصفا

تاريخ: 19/11/2023  
 Name: محمد المصطفى  
 Optimization and its applications

الخطوات: التمييز بين السجود المندرج في السجدة الأولى والثانية

Assume  $\theta = 0$  in ML  $\theta = 0$  optimization stage

1) Initialization (Assign value to parameters  $\theta_1, \theta_n$ )

الحمد لله الذي جعل العلم نوراً يضيء في قلوبنا ويهدينا إلى صراط مستقيم

$\ominus = 0$  Permutation of best all possible solutions

7)  $h_0(x) = y = 0 \cdot x \rightarrow \vec{r}_0$

3) evaluation Prediction  $\rightarrow$  cost function  $\rightarrow$  الدالة البين كلفة

• cross-fitting (loss)  $\rightarrow$  مقارنات  $\rightarrow$  average error (ملاحظة على  $\rightarrow$  MSE  $\rightarrow$   $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ )

$\left( \begin{matrix} \text{observed} \\ \text{msf} \end{matrix} \right) \left( \begin{matrix} \frac{1}{2} \left( \frac{1}{2} - 1 \right) \right)^2 \end{matrix} \right) \left( \begin{matrix} \text{error} \end{matrix} \right)$

حساب واحد بین منظم و رعایتی که بر روی حساب صورتها قدام

ليس صحيحا ان تغير ترسيم العلاقة بين الـ  $\theta$  والـ  $J(\theta)$

$\frac{d}{dt} \left( \frac{1}{\mu_0} \frac{d\mathbf{B}}{dt} \right) = \frac{1}{\mu_0} \frac{d^2 \mathbf{B}}{dt^2}$

4) Direction of Charge  $V_9$  (أولها على الأقل)

charge

7)  $\alpha(\theta) = 0 \Leftrightarrow -(\theta+1) = \theta+1$  nimmt  $\rightarrow$  nicht möglich


ج- لا اتم ابرو خاصه القلي را نه و طلت كنهه (ف)

1954



فوائد Navier-Stokes لنموذج التدفق على سطح متصل، واحد، وحول - الله انشوا حاجه حول Navier-Stokes  
لديهم، حاول اوضح لنا  $\min_{\theta}$  في اقل عدد من ال (استخدامات) (السرع، وقت، انقصر، وقت)  
ونستفيد من، اني يستفيد ال Navier-Stokes (الـ).

استمر ال  $\text{Cost}$  الموجود في ال  $\text{Regression}$  صا  $(MSE, MAE)$



$$MAE = L_{horiz}$$

احصا بيننا وبيننا  $\text{MAE}$  احصا

لي يستفيد ال  $MSE$  احصا وليه يستفيد ال  $MAE$  احصا

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2 = \frac{1}{n} \sum_{i=1}^n (x^{(i)} - y^{(i)})^2$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |x^{(i)} - y^{(i)}|$$

يتفرح احسن لو ال  $\text{MAE}$  احصا

عاز لا ال  $MAE$  فيها ميزات كثير حستكم عن فائدته

لديهم تعرف اي حوال  $\text{Gradient}$   $\frac{df}{dx}$   $\rightarrow$  Direction of  $\text{Rate}$   $\rightarrow$  Amount of Change (Sensitivity) of Change

ما هي حساسية ال  $\theta$  بتغير ال  $\theta$

$$\frac{dJ(\theta)}{d\theta} = 0$$

$\rightarrow$  Direction of  $\text{Rate}$   $\rightarrow$  Amount of Change (Sensitivity) of Change

Direction of  $\text{Rate}$  in the  $\text{Optimal}$  direction

of  $\text{Gradient}$

$MSE$   $\text{Function}$   $\text{Optimal}$

كل  $\text{Rate}$  ال  $\text{Optimal}$   $\text{Direction}$   $\rightarrow$   $\text{Optimal}$   $\text{Direction}$

ال  $MAE$   $\text{Function}$   $\text{Optimal}$   $\text{Direction}$   $\rightarrow$   $\text{Optimal}$   $\text{Direction}$




 $x \rightarrow z \rightarrow A$ 

$$A = \{x \mid w(z) = b\} \mid A = \{x \mid w(z) = b\}$$

المشكلة في دالة

$$y = h(x)$$

Very complex non-linear

أيضا يمكننا استخدام دالة خطية (linear) في Gradient descent معجزة كويس.

الهدف من ان نجعل الخطأ (error) في الحد الأدنى (min) مع تغير قيم w, b.

 $x, y$ 

model has 2 parameters

$$h(x) = \theta_0 + \theta_1 x$$

$$1) \text{ assume } \theta_0 = 0, \theta_1 = 0 \quad \alpha = 1$$

$$2) h(x) = 0$$

$$3) \text{ evaluate error } J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n (h(x_i) - y_i)^2$$

$$4) \left( \frac{\partial J}{\partial \theta_0} \right)_t, \left( \frac{\partial J}{\partial \theta_1} \right)_t$$

$$\nabla J = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{bmatrix}$$

$$\theta_{t+1} = \theta_t - \alpha \left( \frac{\partial J}{\partial \theta_0} \right)_t$$

$$\theta_{t+1} = \theta_t - \alpha \left( \frac{\partial J}{\partial \theta_1} \right)_t$$

كل واحد واحد

مع تغير قيم w, b

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

واحد واحد واحد

لذلك نحتاج ان نصل الى الحد الأدنى (min) مع تغير قيم w, b ولا الاستمرار في التغير.

Gradient = Vector

$$\|\nabla J\| = 0$$

Error

$$J(\theta_0, \theta_1) = \theta_0 + \theta_1 x$$

multiple

$$\text{Gradient} = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{bmatrix}$$

$$G = \nabla \theta_0 + \nabla \theta_1$$

Gradient Descent

 $x_1, x_2, \dots, x_n$ 

$$\nabla \theta = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{bmatrix}$$

لو عندنا

نغير قيمة w, b (function) في كل مرة (iteration) نغيرها.

لذلك نحتاج ان نصل الى الحد الأدنى (min) مع تغير قيم w, b ولا الاستمرار في التغير.

$$\text{يجب } \left( \frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1} \right) = 0$$



**Univariate Regression** →  $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$



مستعارین پارامترها  $\theta_0, \theta_1$  را در یک نقطه قرار می‌دهیم و مقادیر  $\theta_0, \theta_1$  را به دست می‌آوریم.

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x_i - y_i)$$

مقادیر  $\theta_0, \theta_1$  را به دست می‌آوریم.

در Implementation  $\nabla_{\theta} J = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{pmatrix}$

$\theta_{0,t+1} = \theta_{0,t} - \alpha \left( \frac{\partial J}{\partial \theta_0} \right)_t$

$\theta_{1,t+1} = \theta_{1,t} - \alpha \left( \frac{\partial J}{\partial \theta_1} \right)_t$

Single Variable LR

**Multi-variable LR**

$x_1$	$x_2$	$x_3$	$x_n$	$x$
$x_{1,1}$	$x_{1,2}$	$x_{1,3}$	$x_{1,n}$	$x_1$
$x_{2,1}$	$x_{2,2}$	$x_{2,3}$	$x_{2,n}$	$x_2$
$x_{3,1}$	$x_{3,2}$	$x_{3,3}$	$x_{3,n}$	$x_3$
$x_{n,1}$	$x_{n,2}$	$x_{n,3}$	$x_{n,n}$	$x_n$

$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

Parameter Vector =  $\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix}$ ,  $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$

مقادیر  $\theta_0, \theta_1, \theta_2, \dots, \theta_n$  را به دست می‌آوریم.

$h_{\theta}(x) = \theta^T x$

Implementation

$h_{\theta}(x) = [\theta_0 \ \theta_1 \ \theta_2 \ \dots \ \theta_n] \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$  (bias-intercept)

$$\begin{bmatrix} m \times (n+1) \end{bmatrix} \begin{bmatrix} (n+1) \times 1 \end{bmatrix} = \begin{bmatrix} m \times 1 \end{bmatrix}$$

1) initialization  $\theta_{init} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$ ,  $\alpha = \checkmark$

2)  $h_{\theta}(x) = X \theta = \bar{y}$

3)  $J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2$

4)  $\nabla_{\theta} J = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix}$

5)  $\theta_{t+1} = \theta_t - \alpha \frac{\partial J}{\partial \theta}$

Indifference Rule

Fast Training / 19

مقادیر  $\theta_0, \theta_1, \dots, \theta_n$  را به دست می‌آوریم.

$$\begin{pmatrix} \bar{y} \end{pmatrix} = \begin{pmatrix} \bar{y} \end{pmatrix} - \alpha \begin{pmatrix} \bar{y} \end{pmatrix}$$

منکونش قریبہ من بعضہ و یکون ان ا

$\log_{10} x$

<sup>Scale</sup>  
Wm. K. Jr. 11 February 1968

کتاب الیوم فی بیانہ و تفسیرہ

$$\frac{dy}{dx} = \frac{1}{n} \sum_{i=1}^n (h(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

الحفاد عليها .  
 فالتفكير الضيق  $\frac{dJ}{d\omega}$  قليل  $\Delta \omega$  كبير  
 فالتفكير  $\Delta \omega$  كبير

١٠.  $\text{CO}_2$  واحد كيميائي من الحياة. ١٠

[illegible]

من ينظره فالشكر حاصل لما الـ الى الله تعالى كانه خلقه من نفسه

المستفيد من كبريتات الحديد (in the same rule) فكل ما يتعلق به هو الزاد

حتمًا بطرقه :- عرض حاله 'نا و ال Problem' - لو Changes - Minimal

تو Standardization و Calibration

→ Min Max Normalization  $\rightarrow \frac{x_i - \min(x)}{\max(x) - \min(x)}$   $0 \leq x_{\text{norm}} \leq 1$

• اجا نط هي نفس سكر التوزيع الكار عليـ

→ Mean Normalization (Standardization)  $\bar{x} = \frac{x - \bar{x}}{\sigma}$  Sig

ایک توزیع کے لیے Normal Distribution

بشكر الطريقتين دون لوالداتهما (x112)

Robust Statistics  $\rightarrow \bar{y} = \frac{x - Q_1}{Q_3 - Q_1}$

Standardization (التوحيد) وفقاً للتحويل إلى Normal distribution

مع التكرار مع الزاوية  $\theta$  في الـ  $Complex Plane$  هو  $z = re^{i\theta}$

22. 1. R.

حوار Gradient مع محرر المشاكل أيضا يعرفه في برنامج







humboldt (1811) 11 US govt still in, mini 11 govt (1811)  
humboldt

D.1  $\rightarrow$  Advanced optimization for D.1

list of 5 parameters

X → 999

transit in DeLorean Network same as training in and

ازای طیب ۱۴۴۶ هجری قمری  
بدرجہ اولیٰ ازای طیب ۱۴۴۶ هجری قمری

بیا از  $\bar{x}$  و  $y$  اختلاقی (left) ای کارشکلاته اون  $w$  و  $b$  رو پیدا کنیم  
function

$\frac{dJ}{dw}, \frac{dJ}{db}$

N-N 150

0/0 | 0 - 3

gas & chain all at once

Back substitution for  
Graduate

ج ج  $\frac{dT}{d\omega} = \frac{dT}{dA}$   $\rightarrow$  عما، عن سوية حاجات مصروفية في:  $\frac{dT}{d\omega}$

عمر مکمل  $\omega_{t+1} = \omega_t - \alpha \left( \frac{dJ}{dt} \right)$  حاصل طور پر جدائی شریکات

Verdrängung (Gedächtnis)  $\rightarrow$  Verdrängung (Gedächtnis)  $\rightarrow$  Verdrängung (Gedächtnis)

دقة كانت دقة من الواحد وكذا دقة الـ ١٠ اقرب من الواحد ودقة صوديوم الـ ١٠ صوديوم

كبار العلماء ألقوا كلمة " ————— وكتبه محمد عبد الله سلطان ولو كانت الأ

قوة بقطر  $\rightarrow$  exploding  $\rightarrow$   $\frac{dJ}{dt}$  لو كانت القيمة الواحدة  $\frac{dJ}{dt}$  هي كمية

والا يحطو وانما في الحاصل والاعمال كمن فمضطر diverge

المادني في الفيزياء الإشعاعية و Vanishing  
 في Vanishing  
 تستخدم بشكل جيد (D) Momentum based ← إذا زاد التردد

عليه السلام بعد ما ذكره عليه السلام انتهى من الوجه الى ان يكون بيننا قليل لا فاضل عدد

قليل من نفس الوقت من هذا هم يتكلمون من هذا هو

وإنه يكون Confidential الأول وليس Secret في نفس الاتجاه إلى Secret ط 10 أو الإبقاء عليه

12. Moment ~~was~~ 11g 10' Confidente yes

Gradient 4 11

كل ما بعد *Adoration* ولا تفسد ما تشق فوئدنا الا بغيره (Confidence) بنصر الله

Performance of the system is very good.

Object

Date \_\_\_\_\_

momentum  
term

$$\Theta_{t+1} = \Theta_t - \eta x_t$$

①

⑤

$$V_2$$

exponential  
weights & s

سفر

Vibrant

حُتْمَت

27

حَقَّة

• Vermittlung 1:

2.10.10

3.

ila



$$V_t = \delta V_{t-1} + \alpha \nabla \Theta_t$$

~~$\Theta_{x_1} - \Theta_{x_2} - \nabla_{x_1}$~~

مع عن النقطة اة ه ل ل ل ب ا س ل و ب ثا ن

$$\Rightarrow \Theta_{\text{total}} = \Theta_v - (\delta V_f - \gamma) = \text{مقدار جذب}$$

$$\eta(\theta) = \theta \log \theta - \alpha \nabla \theta \log \theta$$

Question: كيف تعامل الزلزال وما العمل لتقليل الأضرار  
Answer: التمسك بالأسطح

~~3)  $V_t = \delta V_{t-1} + \alpha \nabla \Theta^T \Delta_{t-1}$~~

(معمولی و غیر معمولی)

← Normal Deviation 11 slides

$$\ominus x \succ \ominus x$$


$$\text{NAG}$$

$$\Delta I = 1$$

$$V_{\text{induktion}} \rightarrow V_{\text{NAG}}$$

مستشار: د. محمد علي بن عبد الله الجارود

نهر الأحسن على حسب الـ ٢٨٢ نفسها الهندية

اليوم الرابع ( Part 1 ) أفكار السمكة (مادة)  الكتاب (حلوقا)

بالعينة  $feature selection$  من بين المشاكل التي تظهر وتقررت حلها بال (التحليل التوافقي)  $feature selection$

المشكلة تكون في اختيار النماذج  
 dense → sparse  
 (die) → تقدير

وشارر "لما تطور رقم

$$\Delta U = \frac{1}{n} \sum_{i=1}^n h(x^{(i)}) \cdot y^{(i)} \cdot x^{(i)}$$

3. Illustration  $\nabla \theta = \frac{1}{n} \sum_{i=1}^n \nabla \ell(\theta; x^{(i)}, y^{(i)})$

لبن (١٠) املح الماء بمصفاة

صاحب الامر ايراني کي صاحب امور انکسار لکھنا شروع ۵ واصل ۱۲۸۵ھ

عربی ۱۱ (conformant) و ۱۲ (conformant) ۵۰٪

و اة التعمد من خلال ۱۱ ۰



$$v_t = \beta v_{t-1} + (1-\beta) \nabla \theta_t^2 / \alpha \quad \text{Part 2} \quad \frac{\nabla \theta_t^2}{\sqrt{v_t} + \epsilon} \quad \text{hyperparameter } \epsilon$$

$$v_t = \beta v_{t-1} + (1-\beta) (\nabla \theta_t)^2$$

$$v_t = (1-\beta) (\nabla \theta_t)^2$$

$$v_t = \beta v_{t-1} + (1-\beta) (\nabla \theta_t)^2$$

EWMA

$$\rightarrow v_t = \beta(1-\alpha) (\nabla \theta_t)^2 + (1-\beta) (\nabla \theta_t)^2$$

EWMA (Exponential Weighted Moving Average) يقال ميزين

الحل الـ Adam و الـ Rms Prop يقدرنا يتكاملوا مع الـ Gradient Descent

ولا لا!!! وحصل الـ Momentum و الـ NAG يقدرنا يتكاملوا مع الـ Part 2

الـ NAG الـ Momentum يقدرنا يتكاملوا مع الـ Part 2 على عكس الـ Adam و الـ Rms Prop

يعمل القوية طبعاً الـ DL ممكن تقابل الـ Gradient Descent

مع الـ Vanishing Gradient الـ Combine الـ Momentum مع الـ Adam

Momentum + Rms Prop

الـ Momentum الـ Adam

$$\text{another version from momentum} \rightarrow m_t = \beta_1 m_{t-1} + (1-\beta_1) \nabla \theta_t$$

ADAM

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) \nabla \theta_t^2$$

$$\theta_{t+1} = \theta_t + \frac{m_t}{\sqrt{v_t} + \epsilon}$$

$$\text{Real Application } \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}, \alpha \rightarrow 0.001$$

ADAM + mini batch

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)

ADAM (Adam + mini batch)



Single  
Theoretical & Laboratory Experiments  
Vij

objective  $\rightarrow x_{k+1} \Rightarrow f'(x_{k+1}) = 0$

$$\underline{f'(x_{k+1}) = 0 + f'(x_k) + \frac{1}{2} f''(x_k) \cdot (x_{k+1} - x_k)}$$

$$f'(x_k) + f''(x_k) \cdot (x_{k+1} - x_k) = 0$$

$$x_{k+1} - x_k = \frac{-f'(x_k)}{f''(x_k)} \rightarrow x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

ألكندريه  
Newton  
Rothman

Newton کی جگہ

$\min_{x \in S} f(x) = 0$  لا يمكن أن يكون صحيحاً إلا إذا كان  $f(x)$  دائماً غير سالب.

Newton's method  $\rightarrow$  finding the root of the function  $f(x)$  by using the formula  $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$  until it converges to the root.  $\rightarrow$  finding the root of the function  $f(x)$  by using the formula  $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$  until it converges to the root.

فیندستخدام مع ال  $\text{value}$  اس و کلوستغال ری الفلد  $\text{function}$

(from earlier) D-1 algal blooms & crustaceans  
stimulation auto

Muzi Nak Foundation 1.2 Newton

$$\rightarrow \theta_{k+1} = \theta_k - \frac{\bar{J}'(\theta_k)}{J''(\theta_k)}$$

$$\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \cdot \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \rightarrow \nabla F(x_k) \cdot \begin{pmatrix} \frac{\partial F}{\partial \theta_0} \\ \frac{\partial F}{\partial \theta_1} \\ \frac{\partial F}{\partial \theta_2} \\ \vdots \\ \frac{\partial F}{\partial \theta_n} \end{pmatrix} \cdot \tilde{H}(x_k)$$

unvollständiges Jenseits (1. Abschnitt)  
methodisch in der Darstellung

دھرم و ریاضت کے فضائل

• 6th Generation Exposure  $\rightarrow 0.13$   $\leftarrow$  2nd Gen Hxn

تقریباً ربع این در  $M_{eff}$  (یا  $M_{comp}$ ) است که با کسیر جرم و غنی‌سازی کمتری همراه دارد.  
بسیار از داده‌های حاصل از تجزیه کلکولیشن در حیات کسیر (H), H<sup>+</sup>, (OH), (OH)<sup>-</sup>

→ Quasi-Newton method  $x_{k+1} = x_k - H^{-1}(x_k) \cdot \nabla f(x_k)$  ← Newton

$\beta^1 - \beta \leftarrow H_1$  Approximating  $\beta^1$  and  $\beta$

← لما نعلم  $\alpha$  فنسقطه لا  $H$  نجيب  $B$  ونجد  $\alpha$  بعد  $\alpha$   $\alpha$   $\alpha$

اذا حصل  $\text{approximation}$  من  $11^{-1}$  في  $B^{-1}$  فمضروب فترتد  $10^{13}$  مرة ثانية

وهذا عن طريق نقل المعلومات من الذاكرة السابقة وتيسيرها على السائل

لا نحتاج  $\frac{dy}{dx}$  في  $\Delta x$  Dividing  $\Delta y$  by  $\Delta x$  ← select line

derivative approximation

Schlusssatz  
Woffel

→ Affirmationstheorem / Schlußform  
→ Äquivalenztautologie

$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$

منه حصة لا بد منه على كل من  $\Delta$  و  $\Delta'$  والنقاط الخارجة

$$\Rightarrow y_{k+1} = x_k - f(x_k) \cdot \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}$$

$f(x)$  function value at  $x$

$$-B(x_k)(x_k - x_{k-1}) = \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$$
 (Slope condition for minimization)

$$B \cdot \Delta x_k = y_k \rightarrow \Delta x_k = B^{-1} y_k \quad H=2$$

[illegible]

und:  $\lim_{h \rightarrow 0} \frac{h(h\pi)}{2} = \frac{3-9}{2} = 6$   
 Brücken je Brücke die 2 Lagen



Object

Date

/

/

~~فيزياء~~ ~~الميكانيكا~~

Quasi Method

كل نوع من القيود  
Poly Constraints  
في

$$x_{i+1} = x_i - R^{-1} \nabla f(x_i)$$

$$R x = y \rightarrow$$

نوع القيود Quasi المباشرة في الشكل نوع القيود

$$R f(x) \rightarrow$$

نوع القيود Quasi المباشرة في الشكل